Scoring v2 — Bibliographie

PA 26 « End of Life » · les recherches sur lesquelles repose le système de notation · version du 13 octobre 2026

Ce document réunit les **27 articles de recherche** qui fondent le nouveau scoring du jeu : la note de chaque choix sur 100, le passage de chapitre comme unité de note, le niveau, la progression et la fiabilité par chapitre, le délai de 7 jours avant qu'un chapitre rejoué compte, et la validation des points par un panel d'experts. Ils sont classés selon ce à quoi ils ont servi ; sous chacun, une ligne résume ce que nous en retenons. Seuls sont gardés les articles qui justifient une règle du jeu, l'ont inspirée, ou fondent une étape prévue (seuils, validation) : les articles de simple contexte ont été retirés le 13 octobre.

Critères de sélection. Chaque article remplit deux conditions. (1) Il est publié dans une revue scientifique à comité de lecture, ou dans les actes d'une conférence à comité de lecture ; son DOI a été vérifié auprès de Crossref, d'OpenAlex et de PubMed (type de publication, revue, pages, absence de rétractation). (2) Son texte intégral est **gratuit** : le lien « PDF » ouvre l'article sans abonnement ni paiement. Les articles payants sans version gratuite ont été retirés ou remplacés par des articles en libre accès.

Liens. Chaque lien mène à une source sûre : l'éditeur en libre accès, PubMed Central, un dépôt d'université, l'archive HAL ou la page universitaire de l'auteur·e. Tous ont été ouverts dans un navigateur le 12 octobre 2026 ; certains sites font d'abord une vérification automatique de quelques secondes. Une « version acceptée » est le texte accepté après relecture par les pairs, sans la mise en page de la revue.

Le raisonnement complet (mesures, modèle, validation) est dans *docs/Scoring_v2_recherche_et_plan.md* ; le suivi du travail et le détail du tri, dans *docs/Journal_de_developpement.md* (§ 2.26).

1. Nos scènes sont des tests de jugement situationnel (SJT)

1. Patterson, F., Zibarras, L., & Ashworth, V. (2016). Situational judgement tests in medical education and training: Research, theory and practice: AMEE Guide No. 100. *Medical Teacher*, 38(1), 3–17.
Revue de la littérature (guide AMEE) · évalué par les pairs · doi : 10.3109/0142159X.2015.1072619
PDF gratuit : openaccess.city.ac.uk/id/eprint/12506/1/AMEE%20SJT%20Guide%202015.pdf (version acceptée, City Research Online)
Ce que nous en retenons : La référence sur ces tests en éducation médicale : le format (une situation, des réponses possibles, une clé de cotation), son origine et sa validité.

2. de Leng, W. E., Stegers-Jager, K. M., Husbands, A., Dowell, J. S., Born, M. P., & Themmen, A. P. N. (2017). Scoring method of a Situational Judgment Test: influence on internal consistency reliability, adverse impact and correlation with personality? *Advances in Health Sciences Education*, 22(2), 243–265.
Étude empirique · évalué par les pairs · doi : 10.1007/s10459-016-9720-7
PDF gratuit : repub.eur.nl/pub/96435/REPUB_96435-OA.pdf (version publiée, libre accès, Université Érasme de Rotterdam)
Ce que nous en retenons : À l'admission en médecine, la méthode de cotation change la fidélité de la mesure et les écarts entre groupes.

3. Weng, Q., Yang, H., Lievens, F., & McDaniel, M. A. (2018). Optimizing the validity of situational judgment tests: The importance of scoring methods. *Journal of Vocational Behavior*, 104, 199–209.
Étude empirique · évalué par les pairs · doi : 10.1016/j.jvb.2017.11.005
PDF gratuit : ink.library.smu.edu.sg/cgi/viewcontent.cgi?article=6772&context=lkcsb_research (version acceptée, dépôt de la Singapore Management University)
Ce que nous en retenons : Sur cinq méthodes de cotation par consensus, l'une des plus courantes (la cote brute) était la moins valide ; neutraliser les réponses extrêmes améliore la validité.

2. Répétition : pourquoi un délai avant qu'un chapitre rejoué compte

4. Lievens, F., Buyse, T., & Sackett, P. R. (2005). Retest effects in operational selection settings: Development and test of a framework. *Personnel Psychology*, 58(4), 981–1007.
Étude empirique · évalué par les pairs · doi : 10.1111/j.1744-6570.2005.00713.x
PDF gratuit : ink.library.smu.edu.sg/cgi/viewcontent.cgi?article=6678&context=lkcsb_research (manuscrit de l'auteur, dépôt de la Singapore Management University)
Ce que nous en retenons : Repasser le même test fait gagner environ un tiers d'écart-type (admission en médecine, Belgique).

5. Lievens, F., & Sackett, P. R. (2007). Situational judgment tests in high-stakes settings: Issues and strategies with generating alternate forms. *Journal of Applied Psychology*, 92(4), 1043–1055.
Étude empirique · évalué par les pairs · doi : 10.1037/0021-9010.92.4.1043
PDF gratuit : ink.library.smu.edu.sg/cgi/viewcontent.cgi?article=6674&context=lkcsb_research (version acceptée, dépôt de la Singapore Management University)
Ce que nous en retenons : Versions alternatives d'un même test : même de petits changements de contexte changent la mesure.

6. Hausknecht, J. P., Halpert, J. A., Di Paolo, N. T., & Moriarty Gerrard, M. O. (2007). Retesting in selection: A meta-analysis of coaching and practice effects for tests of cognitive ability. *Journal of Applied Psychology*, 92(2), 373–385.
Méta-analyse · évalué par les pairs · doi : 10.1037/0021-9010.92.2.373
PDF gratuit : ecommons.cornell.edu/server/api/core/bitstreams/4fbba765-0d9c-4940-8492-66fecaca5227/content (version acceptée, eCommons, Cornell University)
Ce que nous en retenons : Les gains au retest sont plus forts quand on repasse exactement le même test.

7. Baker, R. S., Corbett, A. T., Koedinger, K. R., & Wagner, A. Z. (2004). Off-task behavior in the cognitive tutor classroom: When students “game the system”. *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems (CHI 2004)*, 383–390.
Étude empirique (actes de conférence) · évalué par les pairs · doi : 10.1145/985692.985741
PDF gratuit : hal.science/hal-00190176/document (archive ouverte HAL)
Ce que nous en retenons : Exploiter les failles d'un logiciel au lieu d'apprendre est lié à un apprentissage plus faible.

3. La note sur 100 et la correction du hasard

8. Frary, R. B. (1988). Formula scoring of multiple-choice tests (correction for guessing). *Educational Measurement: Issues and Practice*, 7(2), 33–38.
Article méthodologique · évalué par les pairs · doi : 10.1111/j.1745-3992.1988.tb00434.x
PDF gratuit : ncme.org/wp-content/uploads/2025/10/Module-4-Formula-Scoring-of-Multiple-choice-Tests-1.pdf (module ITEMS n° 4, site du NCME, éditeur de la revue)
Ce que nous en retenons : Corriger la part due au hasard : base de la note « corrigée du hasard ».

4. Fiabilité : il faut plusieurs situations pour bien mesurer

9. Trejo-Mejía, J. A., Sánchez-Mendiola, M., Méndez-Ramírez, I., & Martínez-González, A. (2016). Reliability analysis of the objective structured clinical examination using generalizability theory. *Medical Education Online*, 21, 31650.
Étude empirique (généralisabilité) · évalué par les pairs · doi : 10.3402/meo.v21.31650
PDF gratuit : pmc.ncbi.nlm.nih.gov/articles/PMC4991996/pdf/MEO-21-31650.pdf (version publiée, PubMed Central)
Ce que nous en retenons : Sur un ECOS de 18 stations (278 étudiant·e·s), la station est l'une des principales sources de variance : la performance dépend de la situation, et seule une mesure sur de nombreuses situations est fiable. D'où le minimum de 8 choix pour noter une compétence.

10. Heeneman, S., de Jong, L. H., Dawson, L. J., Wilkinson, T. J., Ryan, A., Tait, G. R., Rice, N., Torre, D., Freeman, A., & van der Vleuten, C. P. M. (2021). Ottawa 2020 consensus statement for programmatic assessment – 1. Agreement on the principles. *Medical Teacher*, 43(10), 1139–1148.
Déclaration de consensus · évalué par les pairs · doi : 10.1080/0142159X.2021.1957088
PDF gratuit : www.tandfonline.com/doi/pdf/10.1080/0142159X.2021.1957088 (version publiée, libre accès, Taylor & Francis)
Ce que nous en retenons : Évaluation programmatique : chaque mesure sert l'apprentissage ; les décisions importantes reposent sur de nombreuses mesures agrégées.

5. Suivre la progression sur plusieurs passages

11. Howard, N., Edwards, R., Boutis, K., Alexander, S., & Pusic, M. (2023). Twelve tips for using learning curves in health professions education research. *MedEdPublish*, 13, 269.
Article méthodologique · évalué par les pairs · doi : 10.12688/mep.19723.1
PDF gratuit : pmc.ncbi.nlm.nih.gov/articles/PMC10696298/pdf/mep-13-21130.pdf (version publiée, PubMed Central)
Ce que nous en retenons : Les courbes d'apprentissage et leurs seuils : une courbe par chapitre rejoué.

12. Nissen, J. M., Talbot, R. M., Nasim Thompson, A., & Van Dusen, B. (2018). Comparison of normalized gain and Cohen's d for analyzing gains on concept inventories. *Physical Review Physics Education Research*, 14(1), 010115.
Étude empirique · évalué par les pairs · doi : 10.1103/PhysRevPhysEducRes.14.010115
PDF gratuit : link.aps.org/pdf/10.1103/PhysRevPhysEducRes.14.010115 (version publiée, libre accès, American Physical Society)
Ce que nous en retenons : Le gain normalisé et le changement normalisé : la progression rapportée à ce qui restait à gagner. Mise en garde : ils favorisent les personnes qui partent haut.

13. Corbett, A. T., & Anderson, J. R. (1995). Knowledge tracing: Modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4(4), 253–278.
Étude empirique · évalué par les pairs · doi : 10.1007/BF01099821
PDF gratuit : act-r.psy.cmu.edu/wordpress/wp-content/uploads/2012/12/893CorbettAnderson1995.pdf (version publiée numérisée, groupe ACT-R, Carnegie Mellon University)
Ce que nous en retenons : Estimer le niveau actuel d'un·e apprenant·e à partir de ses essais successifs.

14. Pelánek, R. (2017). Bayesian knowledge tracing, logistic models, and beyond: an overview of learner modeling techniques. *User Modeling and User-Adapted Interaction*, 27(3–5), 313–350.
Revue de la littérature · évalué par les pairs · doi : 10.1007/s11257-017-9193-2
PDF gratuit : www.fi.muni.cz/~xpelanek/publications/umuai-overview.pdf (version acceptée, page de l'auteur, Université Masaryk)
Ce que nous en retenons : Juger un modèle de niveau à sa capacité à prédire le passage suivant : méthode prévue pour calibrer le coefficient 0,25.

15. Legoux, C., Gerein, R., Boutis, K., Barrowman, N., & Plint, A. (2021). Retention of critical procedural skills after simulation training: A systematic review. *AEM Education and Training*, 5(3), e10536.
Revue systématique · évalué par les pairs · doi : 10.1002/aet2.10536
PDF gratuit : pmc.ncbi.nlm.nih.gov/articles/PMC8166305/pdf/AET2-5-e10536.pdf (version acceptée, PubMed Central)
Ce que nous en retenons : Les compétences acquises en simulation baissent avec le temps : une vieille performance représente moins bien le niveau actuel.

6. Faire valider les points par un panel d'experts

16. Jünger, S., Payne, S. A., Brine, J., Radbruch, L., & Brearley, S. G. (2017). Guidance on Conducting and REporting DElphi Studies (CREDES) in palliative care: Recommendations based on a methodological systematic review. *Palliative Medicine*, 31(8), 684–706.
Revue systématique méthodologique · évalué par les pairs · doi : 10.1177/0269216317690685
PDF gratuit : eprints.lancs.ac.uk/id/eprint/84723/1/Submission_PM_06_12_2016.pdf (version acceptée, Lancaster EPrints)
Ce que nous en retenons : La méthode Delphi en soins palliatifs : comment la conduire et en rendre compte (tours, seuil de consensus, choix des experts).

17. Koo, T. K., & Li, M. Y. (2016). A guideline of selecting and reporting intraclass correlation coefficients for reliability research. *Journal of Chiropractic Medicine*, 15(2), 155–163 ; erratum : 16(4), 346 (2017).
Article méthodologique · évalué par les pairs · doi : 10.1016/j.jcm.2016.02.012
PDF gratuit : pmc.ncbi.nlm.nih.gov/articles/PMC4913118/pdf/main.pdf (version publiée, PubMed Central)
Ce que nous en retenons : Les formes de l'ICC (dont l'accord absolu utilisé ici) et les seuils pour l'interpréter : faible, modéré, bon (≥ 0,75), excellent (≥ 0,9).

7. Les cadres qui définissent les compétences (grille d'évaluation)

18. Michaud, P.-A., & Jucker-Kupper, P. (2016). The “Profiles” document: a modern revision of the objectives of undergraduate medical studies in Switzerland. *Swiss Medical Weekly*, 146, w14270.
Article de cadre de référence · évalué par les pairs · doi : 10.4414/smw.2016.14270
PDF gratuit : smw.ch/index.php/smw/article/download/2150/3178 (version publiée, libre accès, Swiss Medical Weekly)
Ce que nous en retenons : PROFILES, le cadre suisse des objectifs de formation médicale.

19. Joyce, B. L., Steenbergh, T., & Scher, E. (2010). Use of the Kalamazoo Essential Elements Communication Checklist (Adapted) in an institutional interpersonal and communication skills curriculum. *Journal of Graduate Medical Education*, 2(2), 165–169.
Étude empirique · évalué par les pairs · doi : 10.4300/JGME-D-10-00024.1
PDF gratuit : pmc.ncbi.nlm.nih.gov/articles/PMC2941375/pdf/i1949-8357-2-2-165.pdf (version publiée, PubMed Central)
Ce que nous en retenons : Les 7 éléments essentiels de la communication de Kalamazoo, cotés de façon cohérente par les tuteurs, les patients standardisés et les étudiant·e·s.

20. Simmenroth-Nayda, A., Heinemann, S., Nolte, C., Fischer, T., & Himmel, W. (2014). Psychometric properties of the Calgary Cambridge guides to assess communication skills of undergraduate medical students. *International Journal of Medical Education*, 5, 212–218.
Étude empirique · évalué par les pairs · doi : 10.5116/ijme.5454.c665
PDF gratuit : www.ijme.net/archive/5/psychometric-properties-of-the-calgary-cambridge-guides.pdf (version publiée, libre accès, IJME)
Ce que nous en retenons : Le guide Calgary-Cambridge de l'entretien médical, utilisable pour évaluer la communication d'étudiant·e·s en début de cursus.

8. Erreurs graves, seuils de réussite et validité de la note

21. Homer, M., & Russell, J. (2021). Conjunctive standards in OSCEs: The why and the how of number of stations passed criteria. *Medical Teacher*, 43(4), 448–455.
Article méthodologique · évalué par les pairs · doi : 10.1080/0142159X.2020.1856353
PDF gratuit : eprints.whiterose.ac.uk/id/eprint/168283/3/ConjunctiveStandardsOSCE_ResubUpload.pdf (version acceptée, White Rose Research Online)
Ce que nous en retenons : Pourquoi et comment limiter la compensation à l'ECOS (règle non compensatoire) : base de la règle « une erreur critique ne se compense pas ».

22. Dwyer, T., Wright, S., Kulasegaram, K. M., Theodoropoulos, J., Chahal, J., Wasserstein, D., Ringsted, C., Hodges, B., & Ogilvie-Harris, D. (2016). How to set the bar in competency-based medical education: standard setting after an Objective Structured Clinical Examination (OSCE). *BMC Medical Education*, 16, 1.
Étude empirique · évalué par les pairs · doi : 10.1186/s12909-015-0506-z
PDF gratuit : link.springer.com/content/pdf/10.1186/s12909-015-0506-z.pdf (version publiée, libre accès, BMC)
Ce que nous en retenons : Fixer le seuil de réussite avec des juges (Angoff modifié) : méthode crédible, comparée aux méthodes des cas limites.

23. Cook, D. A., & Hatala, R. (2016). Validation of educational assessments: a primer for simulation and beyond. *Advances in Simulation*, 1, 31.
Revue méthodologique · évalué par les pairs · doi : 10.1186/s41077-016-0033-y
PDF gratuit : link.springer.com/content/pdf/10.1186/s41077-016-0033-y.pdf (version publiée, libre accès, BMC)
Ce que nous en retenons : Démontrer qu'une note mesure ce qu'elle prétend mesurer : l'argument de validité (cadres de Kane et de Messick).

24. Blanié, A., Amorim, M.-A., Meffert, A., Perrot, C., Dondelli, L., & Benhamou, D. (2020). Assessing validity evidence for a serious game dedicated to patient clinical deterioration and communication. *Advances in Simulation*, 5, 4.
Étude empirique de validité · évalué par les pairs · doi : 10.1186/s41077-020-00123-3
PDF gratuit : link.springer.com/content/pdf/10.1186/s41077-020-00123-3.pdf (version publiée, libre accès, BMC)
Ce que nous en retenons : Contre-exemple : un jeu sérieux dont le score ne distinguait pas étudiant·e·s et expert·e·s.

9. Feedback et patients virtuels

25. Wisniewski, B., Zierer, K., & Hattie, J. (2020). The power of feedback revisited: A meta-analysis of educational feedback research. *Frontiers in Psychology*, 10, 3087.
Méta-analyse · évalué par les pairs · doi : 10.3389/fpsyg.2019.03087
PDF gratuit : www.frontiersin.org/articles/10.3389/fpsyg.2019.03087/pdf (version publiée, libre accès, Frontiers)
Ce que nous en retenons : Sur 435 études, le feedback a un effet moyen (d = 0,48), d'autant plus fort qu'il apporte d'information sur la tâche.

26. Shute, V. J. (2008). Focus on formative feedback. *Review of Educational Research*, 78(1), 153–189.
Revue de la littérature · évalué par les pairs · doi : 10.3102/0034654307313795
PDF gratuit : myweb.fsu.edu/vshute/pdf/shute%202008_b.pdf (version publiée, page de l'autrice, Florida State University)
Ce que nous en retenons : Le feedback formatif : non jugeant, au bon moment, précis.

27. Lee, J., Kim, H., Kim, K. H., Jung, D., Jowsey, T., & Webster, C. S. (2020). Effective virtual patient simulators for medical communication training: A systematic review. *Medical Education*, 54(9), 786–795.
Revue systématique · évalué par les pairs · doi : 10.1111/medu.14152
PDF gratuit : asmepublications.onlinelibrary.wiley.com/doi/pdfdirect/10.1111/medu.14152 (version publiée, accès libre chez l'éditeur, Wiley)
Ce que nous en retenons : Avec les patients virtuels en communication, c'est le débriefing humain qui rend l'outil efficace, pas le feedback automatique seul.